BERTopic

1. Introducción y corpus

Se aplica BERTopic para encontrar los tópicos de un corpus de noticias en español.

- **Fuente:** MLSUM-es (Scialom et al., 2020), split `test`: artículos de *El País* (junio–octubre 2019), descargados de Hugging Face.
- **Idioma:** español.
- **Tamaño:** 13 920 artículos.

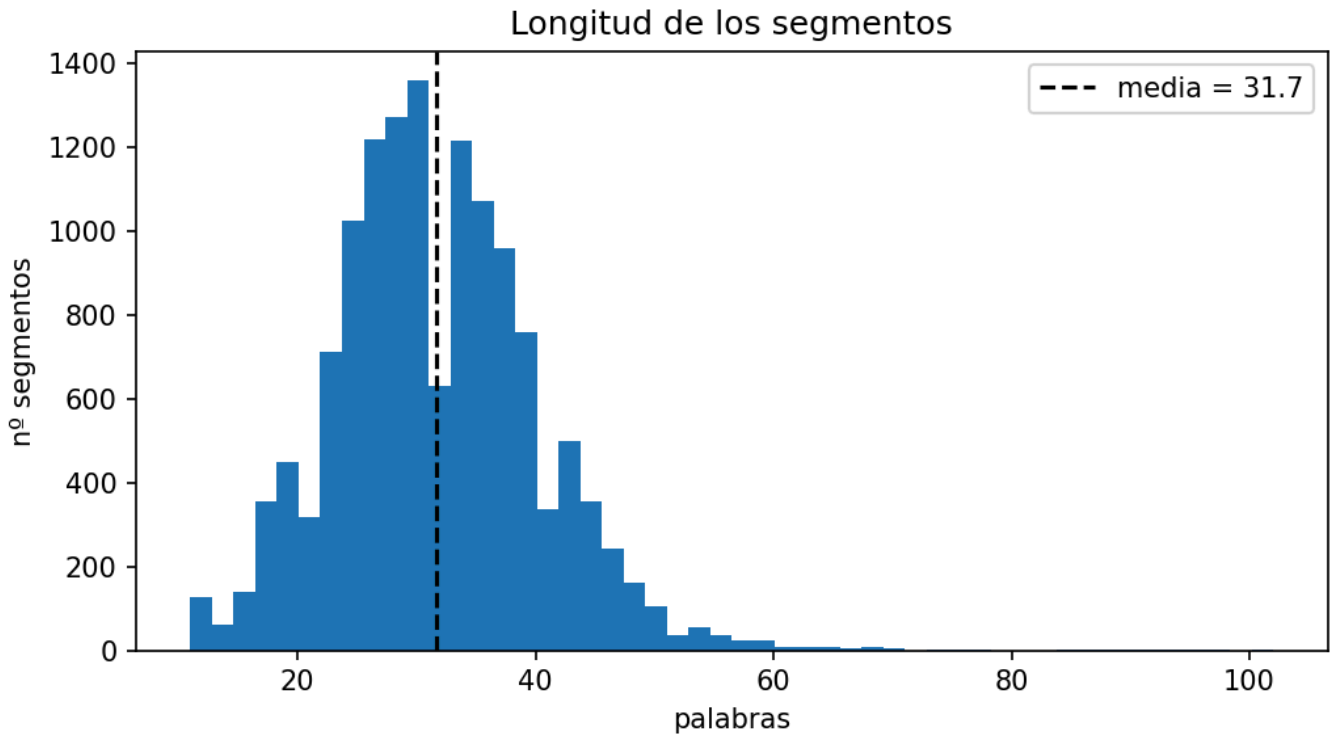
2. Segmentación

Criterio: 1 documento = título + resumen de un artículo.

La unidad de análisis debe ser autocontenida y, a la vez, caber en la ventana de contexto del codificador. El cuerpo de los artículos mide ~784 palabras y no tiene saltos de párrafo en el dataset, lo que impide segmentarlo por párrafo; además, excede el límite de 128 tokens del modelo. El título y el resumen, en cambio, son una síntesis editorial del artículo.

Limpieza: se eliminaron 305 artículos en inglés (sección *elpais inenglish*) y 2 duplicados que crearían falsas regiones de alta densidad en el clustering.

Estadística	Valor
Segmentos	13 613
Longitud promedio	31.7 palabras (46.7 tokens)
Segmentos truncados (> 128 tokens)	0.11 %



3. Metodología

- **Embeddings:** `paraphrase-multilingual-mpnet-base-v2` (Reimers & Gurevych, 2020). Es un transformer que convierte cada texto en un vector de 768 dimensiones, de forma que textos con significado parecido quedan cerca entre sí. Se entrenó por **destilación de conocimiento**: un modelo "estudiante" multilingüe aprende, con pérdida MSE, a imitar los vectores de un modelo "maestro" en inglés. Así, el español queda representado en el mismo espacio semántico. Se eligió porque es multilingüe, es el recomendado por BERTopic para idiomas distintos del inglés y su límite de 128 tokens cubre nuestros segmentos.

- **UMAP:** `n_neighbors=15, n_components=5, min_dist=0.0, metric="cosine", random_state=14`. Agrupar directamente en 768 dimensiones funciona mal, porque en espacios tan grandes todas las distancias se parecen. UMAP reduce los vectores a 5 dimensiones conservando qué documentos son vecinos entre sí. Se usa la distancia coseno, que es la adecuada para embeddings; `min_dist=0` deja los grupos compactos, lo que facilita el clustering; y `random_state` hace que los resultados sean reproducibles.

- **HDBSCAN:** algoritmo de clustering por densidad: forma un tópico donde hay muchos documentos cercanos entre sí. A diferencia de k-means, no hay que decirle cuántos tópicos buscar, y no obliga a meter cada documento en un grupo: los que no encajan en ninguno quedan como outliers. `min_cluster_size` define el tamaño mínimo de un tópico.

- **CountVectorizer y c-TF-IDF:** para describir cada tópico, BERTopic busca las palabras más características de sus documentos frente al resto del corpus (c-TF-IDF). Se usaron stopwords en español (NLTK más palabras frecuentes en noticias como *tras, según, año*) para que palabras vacías como *de, la, que* no dominen las descripciones, y `min_df=5` para ignorar palabras demasiado raras.

Configuraciones comparadas:

Config	`min_cluster_size`	Selección	`ngram_range`	`nr_topics`	MMR	Tópicos	% outliers	Tópico más grande
A	30	`eom`	(1,1)	None	No	77	36.6	852
B	80	`leaf`	(1,2)	None	Sí (0.3)	42	40.9	586
C	50	`leaf`	(1,2)	None	Sí (0.3)	62	45.6	375

`ngram_range` define si las palabras clave son solo palabras sueltas `(1,1)` o también pares de palabras `(1,2)`, como *cambio climático*; afecta la descripción de los tópicos, no la agrupación. `nr_topics` fusiona los tópicos más parecidos hasta llegar a un número dado; se dejó en `None` porque el número de tópicos se controló con `min_cluster_size`.

La comparación muestra un compromiso entre **detalle e interpretabilidad**. A genera muchos tópicos muy específicos y, a la vez, un tópico enorme (852 documentos) que mezcla toda la política nacional (PSOE, PP, Podemos). B produce tópicos más amplios y fáciles de interpretar: la selección `leaf` reparte mejor los tamaños (el tópico más grande baja de 852 a 586 documentos), los bigramas captan expresiones como *cambio climático* o *madrid central*, y MMR evita palabras clave repetitivas. C, que solo baja `min_cluster_size` a 50, queda en un punto intermedio (62 tópicos), pero deja más outliers (45.6 %) y vuelve a dividir algunos temas en tópicos más pequeños. **Se eligió B.**

4. Resultados

4.1 Outliers

B deja **40.9 %** de outliers. Esto es normal en un clustering por densidad: columnas de opinión, piezas únicas o temas con pocos artículos no forman grupos. Para recuperarlos sin forzar asignaciones, se usó `reduce_outliers(strategy="embeddings", threshold=0.5)`: cada outlier se asigna al tópico más parecido (similitud coseno) solo si la similitud es al menos 0.5; los ambiguos siguen como –1. Resultado: **11.6 %** de outliers.

4.2 Tabla de tópicos

Topic	Nombre	Docs	Palabras clave
-1	Outliers	1582	china, hong kong, kong, hong, millones, 000, vida, euros
0	Música y celebridades	741	cantante, música, festival, actriz, musical, disco, vida, concierto
1	Cambio climático y sostenibilidad	537	climático, cambio climático, cambio, planeta, climática, global, sostenible, clima
2	Fútbol	474	fútbol, equipo, mundial, real madrid, atlético, madrid, partido, real
3	Sucesos y detenciones	442	detenido, hombre, mujer, policía, víctima, prisión, joven, detenidos
4	Repetición electoral (10-N)	586	elecciones, política, políticos, electoral, partidos, pactos, democracia, debate
5	Tribunales y justicia	494	juez, tribunal, supremo, torra, caso, fiscalía, sentencia, juicio
6	Economía española y global	454	economía, banco, deuda, españa, millones, tipos, crecimiento, empleo
7	Guía de TV y resumen diario (formato)	313	ver, 2019, actualidad, historias, jornada, noticias, clave, selección
8	Ofertas y compras (Escaparate)	245	mejores, ofertas, amazon, precios, productos, 15, selección, modelos
9	Cataluña y el procés	394	cataluña, barcelona, españa, procés, catalán, independentismo, catalana, sentencia
10	Geopolítica: Trump, Israel, Irán	264	trump, uu, ee uu, ee, israel, irán, presidente, donald
11	Violencia de género y feminismo	306	mujeres, violencia, género, sexual, mujer, orgullo, machista, igualdad
12	Ayuntamiento de Madrid / Madrid Central	384	madrid, madrid central, central, ayuntamiento, metro, ciudad, alcalde, capital
13	Realeza	226	príncipe, princesa, reina, boda, hijo, inglaterra, isabel, isabel ii
14	Cine de Hollywood y novela	332	película, cine, novela, serie, hollywood, actor, literatura, películas
15	Salud y brotes sanitarios	213	brote, enfermedad, sanidad, cáncer, enfermedades, pacientes, salud, andalucía
16	Viajes y hoteles	303	ciudad, ruta, verano, hoteles, fotos, hotel, barrio, viaje
17	Educación	201	educación, alumnos, escuela, escolar, colegio, estudiantes, universidad, universidades
18	México y Venezuela	253	méxico, maduro, venezuela, obrador, lópez obrador, país, lópez, ee uu
19	Migración y Open Arms	208	migrantes, arms, open arms, open, inmigrantes, refugiados, barco, menores
20	Brexit	156	brexit, johnson, boris, reino unido, unido, reino, boris johnson, británico
21	Motor, tenis y ciclismo	184	nadal, márquez, carrera, mundial, gana, marc, final, horarios
22	Unión Europea	204	ue, europa, europea, macron, unión, europeo, unión europea, alemania
23	Exhumación de Franco	216	franco, exhumación, exhumación franco, dictador, caídos, valle, valle caídos, restos
24	Literatura y libros	397	libro, escritor, libros, novela, literatura, español, juan, muere
25	Arte y museos	283	arte, museo, exposición, artista, obra, contemporáneo, prado, obras
26	Gastronomía y restaurantes	163	restaurantes, chef, restaurante, cocina, madrid, recetas, vino, receta
27	Medios de comunicación y ensayo de opinión	300	medios, historia, veces, tiempo, gente, verdad, mundo, vida

Topic	Nombre	Docs	Palabras clave
28	Colombia y Bolivia	241	colombia, paz, bolivia, morales, presidente, país, duque, gobierno
29	Accidentes	130	accidente, muere, vídeo, coche, heridos, muertos, avión, tráfico
30	Festivales de cine y viñetas de El Roto (mixto)	422	roto, 2019, festival, cine, teatro, octubre, junio 2019, octubre 2019
31	Crianza e infancia	172	niños, hijos, padres, mujeres, tener, embarazo, desarrollo, niñas
32	Incendios forestales	134	incendio, fuego, incendios, amazonia, canaria, gran canaria, hectáreas, gran
33	Alimentación y dieta	136	comer, carne, alimentos, comida, productos, dieta, alimentación, salud
34	Vivienda y alquiler	140	vivienda, viviendas, alquiler, pisos, precio, piso, casas, precios
35	PSOE-Podemos: gobierno de coalición	297	psoe, podemos, socialistas, gobierno, unidas podemos, pp, coalición, unidas
36	Investidura de Sánchez	246	sánchez, iglesias, investidura, pedro sánchez, pedro, podemos, presidente, psoe
37	Resultados empresariales	162	millones, compañía, ventas, españa, grupo, euros, beneficio, coches
38	Privacidad y redes sociales	110	datos, facebook, privacidad, usuarios, whatsapp, información, redes, aplicación
39	PP, Ayuso y Ciudadanos	347	pp, ayuso, díaz, díaz ayuso, rivera, ciudadanos, vox, cs
40	Inteligencia artificial y economía digital	131	digital, inteligencia artificial, google, artificial, inteligencia, tasa, tecnología, internet
41	Huelgas en aeropuertos	90	huelga, pasajeros, aeropuerto, aerolínea, vuelos, volar, prat, cook

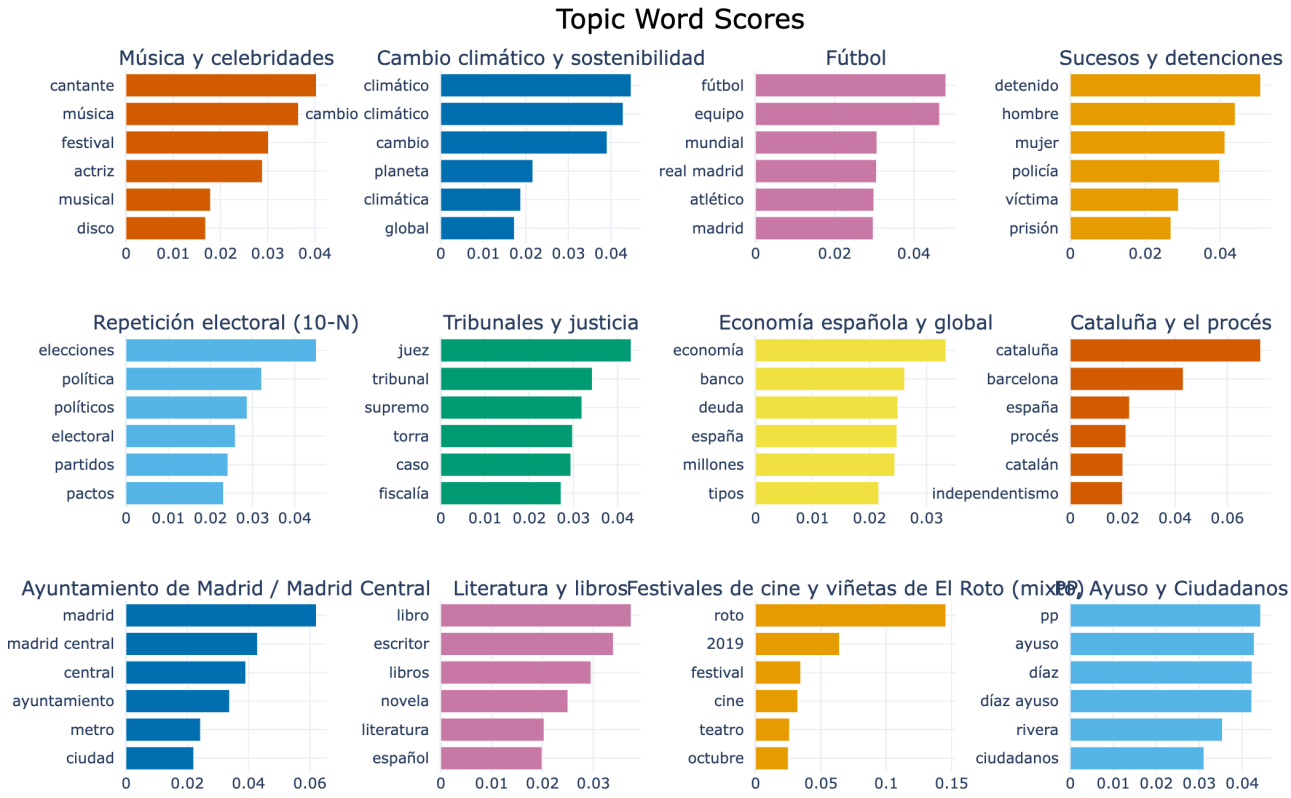
4.3 Segmentos representativos

Se muestran 2 segmentos para 10 tópicos representativos; la lista completa (2 por cada uno de los 42 tópicos) está en el notebook y en `segmentos_representativos.csv`.

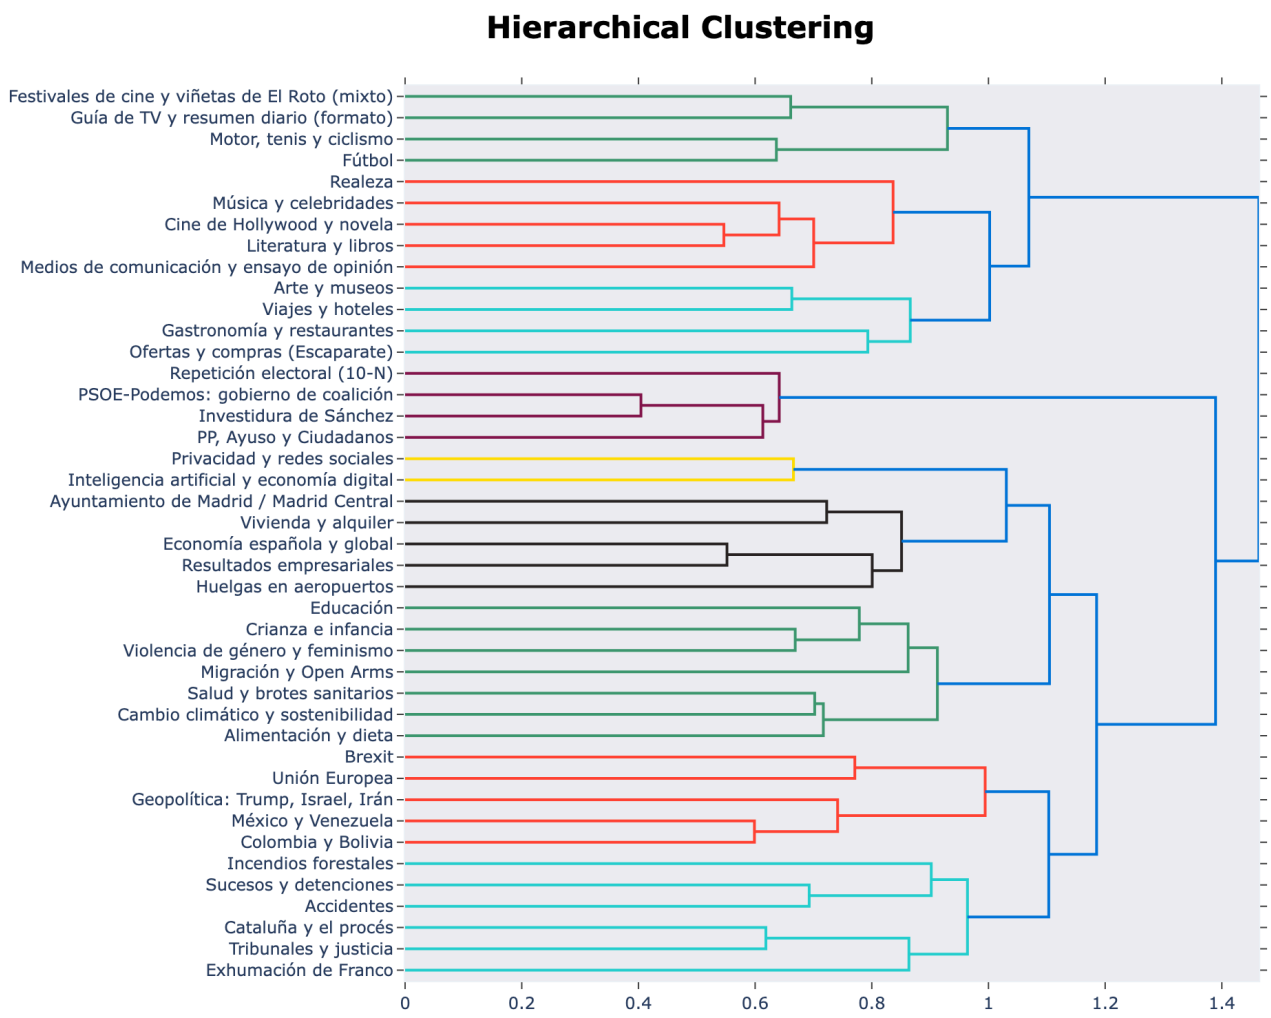
Topic	Nombre	Segmento
1	Cambio climático y sostenibilidad	Cambio climático: No es suficiente. Los Gobiernos deben asumir mayores compromisos ante el cambio climático
1	Cambio climático y sostenibilidad	cambio climático: El reto político del cambio climático. Exijamos a nuestros líderes que lean a nuestros científicos y que actúen en consecuencia. No tenemos un planeta B
2	Fútbol	La nueva fábrica de jugadoras. Cómo el fútbol español copa el Mundial de Francia. Una de cada 10 futbolistas del torneo compitieron la última temporada en España. El FC Barcelona, con 15, es el club c…
2	Fútbol	Mundial de Fútbol Femenino 2019: resultados de los partidos. Estados Unidos gana la octava edición de la Copa Mundial Femenina de fútbol en Francia. Así ha sido el resto de partidos
4	Repetición electoral (10-N)	10-N: ¿Fin de la política?. No son los políticos en tanto que personas, es la política en tanto que poder la que está cada vez más limitada y desorientada
4	Repetición electoral (10-N)	Elecciones generales: En el tablero no hay sitio para el acuerdo. La repetición de las elecciones generales puede explicarse por una combinación de factores sistémicos con la debilidad organizativa e …
5	Tribunales y justicia	El Tribunal Supremo descarta el delito de rebelión consumada. La condena por este delito habría implicado de 15 a 25 años de cárcel. Las penas para los líderes del 'procés' serán escalonadas según la …
5	Tribunales y justicia	El juez acuerda enviar a juicio a Torra por no retirar los lazos amarillos. La Fiscalía pide para el presidente una condena de un año y ocho meses de inhabilitación
6	Economía española y global	El Banco de España calcula que se perderán 95 millones por los aranceles de EE UU. El supervisor advierte de que los aumentos de barreras arancelarias tienen un impacto adverso y persistente sobre la …

Topic	Nombre	Segmento
6	Economía española y global	Funcas rebaja al 1,9% su previsión de crecimiento del PIB para 2019 y apunta a un “final de ciclo, no a una recesión”. La economía española crecerá en 2020 un 1,5%, cinco décimas menos de lo anteriorm…
9	Cataluña y el procés	Cataluña: Para un mapa sin territorio. No hay interlocutor político en Cataluña fiable y serio, y lo más importante: que sea representativo de la sociedad catalana en su conjunto. En la fórmula clásic…
9	Cataluña y el procés	Una jornada de tregua en Cataluña. Las voces agoreras que alertaban de un día de elecciones caliente en Cataluña quedaron en nada
19	Migración y Open Arms	Open Arms: La prioridad. Los náufragos del ‘Open Arms’ tienen que ser desembarcados cuanto antes
19	Migración y Open Arms	Los 15 migrantes del ‘Open Arms’ irán al centro de inmigrantes (CETI) de Chiclana de la Frontera. Los rescatados, 14 hombres y una mujer, llegarán este viernes en el buque ‘Audaz’
20	Brexit	Las ocho fracturas del Brexit. Queda menos para la salida o queda menos para Boris Johnson, porque el Brexit nos entierra a todos
20	Brexit	Brexit: Johnson derrotado. El Parlamento británico desbarata los planes de un Brexit duro
23	Exhumación de Franco	Exhumación Franco: Parte del pasado. La derrota de la dictadura fue la Constitución, no la exhumación de Franco
23	Exhumación de Franco	Exhumación de Franco: Fin de la anomalía. El Supremo abre el camino para exhumar los restos de Franco del Valle de los Caídos
35	PSOE-Podemos: gobierno de coalición	Iglesias pide “una oportunidad” a los “socialistas de corazón”. Unidas Podemos apela a los simpatizantes del PSOE que "no han perdido la esperanza de un Gobierno conjunto"
35	PSOE-Podemos: gobierno de coalición	Sánchez e Iglesias alcanzan un acuerdo para formar un Gobierno de coalición. El PSOE y Unidas Podemos buscan pactos con otros partidos para alcanzar la mayoría. El líder de la formación morada será vi…

4.4 Visualizaciones



Barchart: muestra las palabras más características (c-TF-IDF) de cada tópico. Los tópicos principales tienen vocabularios claros y distintos entre sí (*fútbol/equipo/mundial*, *juez/tribunal/supremo*, *cambio climático/planeta*), lo que indica que están bien separados.



Jerarquía: agrupa los tópicos según su parecido. Se forman macrotemas lógicos: política española, internacional, sucesos y justicia, sociedad, cultura, estilo de vida y deportes. Los dos tópicos de formato se unen a la rama de deportes, porque las guías de TV anuncian partidos televisados: se parecen por su estructura, no por su tema. Además, *PSOE-Podemos: gobierno de coalición* e *Investidura de Sánchez* se fusionan a muy poca distancia (0.41), señal de que son casi el mismo tópico.

5. Discusión y conclusiones

Tópicos con sentido: la mayoría, sobre todo los que corresponden a eventos de la agenda informativa de 2019: exhumación de Franco, Open Arms, Madrid Central, repetición electoral del 10-N, Brexit e incendios. Que un método no supervisado los encuentre muestra que los embeddings capturan bien el significado de las noticias en español.

Tópicos sin sentido o débiles:

- **Tópicos de formato:** la *Guía de TV* y el *resumen diario de noticias* (tópico 7) se agrupan porque siguen la misma plantilla, no porque traten el mismo tema. Los embeddings detectan esa similitud superficial y forman un grupo.

- **Tópico 30 (mixto):** junta festivales de cine y teatro con las viñetas diarias de El Roto; sus palabras clave incluyen fechas (*junio 2019, octubre 2019*), lo que delata la plantilla de las viñetas.
- **Tópico 27** (medios/opinión): palabras clave genéricas (*medios, historia, tiempo, gente*); agrupa columnas parecidas en estilo, no en contenido.
- **Mezclas y solapamientos:** el tópico 0 junta música con actrices y celebridades; los tópicos 35 y 36 tratan el mismo asunto (el pacto PSOE-Podemos) desde dos ángulos.
- **Temas pequeños perdidos:** las protestas de Hong Kong (58 artículos) no llegan a `min_cluster_size=80` y no forman tópico propio; *hong kong* aparece entre las palabras principales de los outliers. Este parámetro determina el tema más pequeño que el modelo puede detectar.

Conclusión: BERTopic recupera bien los temas principales del corpus, pero el resultado depende de decisiones de diseño: cómo se segmenta el texto, el tamaño mínimo de clúster y el método de selección de HDBSCAN.

6. Bibliografía

- Grootendorst, M. (2022). *BERTopic: Neural topic modeling with a class-based TF-IDF procedure*. arXiv:2203.05794.
- Scialom, T. et al. (2020). *MLSUM: The Multilingual Summarization Corpus*. EMNLP.
- Reimers, N., & Gurevych, I. (2020). *Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation*. EMNLP.
- McInnes, L., Healy, J., & Melville, J. (2018). *UMAP*. arXiv:1802.03426.
- Campello, R., Moulavi, D., & Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates*. PAKDD.

7. Declaración de uso de IA

Se usó **Claude Code** (Anthropic, Claude Opus 5.5) como apoyo para escribir el código y el borrador de este reporte. El modelo se encargó de asignar las labels a los tópicos resultantes, mientras que las decisiones como el dataset o metodología fueron planificadas con ayuda de este modelo pero siempre con decisión final mía.

8. Código

https://github.com/BaltazarSR/BERTopic